

2025 DATA·AI 분석 경진대회

지속가능한 수자원을 위한 지하수 함양 특성 분석 및 AI 기반 지하수위 변동 예측

2025.10.16.

TEAM. 아쿠아리움

I. 개요

○ 연구 배경 및 주제 선정

지하수는 우리나라 생활용수와 농업용수에서 중요한 비중을 차지하고 있으며 기후변화와 물 부족 문제에 대응하는 핵심 자원이다. 특히 지하수위의 변동은 기후 및 강수와 밀접하게 연관되어 있어, 지하수위 예측을 통한 선제적 관리와 대응이 점점 더 중요해지고 있다.

- 최근 기후변화로 인한 가뭄·홍수 등의 이상 기후 발생 및 물 공급의 지역적 불균형에 의한 물 부족 현상 발생 빈도가 증가하면서 수자원의 안정적인 공급 및 체계적인 관리에 대한 중요성이 대두되고 있음. 지하수 자원은 이러한 문제에 대한 대안이 될 수 있는 청정 수자원임(윤희성 외, 2016).

- 특히 지하수는 지구의 물리적 환경과 다양한 요소로 연결되어 상호작용하며 물 순환의 주요한 영향력을 가짐. 또한 지하수는 전 세계 담수의 약 99%를 차지하고 전 세계 생활용수의 약 50%를, 그리고 38%의 관개 농경지에 공급할 수 있는 전체 농업용수의 약 25%를 공급하는 등 전 세계 수자원 공급에 큰 부분을 차지함(UN 세계 물개발 보고서, 2022).

- 그러나 최근 전 세계적인 기후변화로 인해 지하수자원의 안정성이 위협받고 있으며 이러한 상황과 동시에 생활 수준의 향상 등으로 인한 물 수요 증가까지 더해지고 있음. 또한 가뭄이 가속화됨에 따라 지표수량이 감소하여 지하수에 대한 의존도가 높아지고 있음(최광복 외, 2020).

○ 연구 목적

본 연구의 목적은 기후 및 강수 요인에 따른 지하수위 변동을 정량적으로 예측하고 안정적인 수자원 관리 방안을 제시하는 데 있다. 본 연구를 통해 지하수위 예측의 정확도를 높이고, 기후변화로 인한 상황에 선제적으로 대응할 수 있는 과학적 근거를 마련하고자 한다.

Ⅱ. 활용 데이터

○ 활용 데이터

본 프로젝트는 2025 DATA·AI 분석 경진대회에서 제공한 데이터를 사용하여 분석을 진행했다. 제공 데이터에는 각 지점별로 시간대별 지하수위, 전기전도도, 강수량, 기온 등의 정보를 담고 있어 제공데이터만으로도 기상환경에 따른 지하수위를 예측하는데 충분하다고 예상된다.

○ 데이터 설명

① 12개 지하수 지점 정보

본 데이터는 주최 측에서 정한 12곳의 지하수 지점의 위도, 경도, 수리전도도, 표고, 관측망 유형에 대한 정보를 담고 있다.

② 2014-2020 시계열 지하수 기상 train

본 데이터에는 지점별 2014-01-01 12:00:00AM ~ 2020-12-31 23:00:00PM까지의 시간대별 지하수위, 수온, 전기전도도, 기온 ...등 지하수위를 포함한 여러 가지 기상 정보가 담고 있다.

③ 2021-2023 시계열 지하수 기상 test

본 데이터에는 지점별 2021-01-01 12:00:00AM ~ 2023-12-31 23:00:00PM까지의 시간대별 수온, 전기전도도, 기온 ...등 지하수위를 제외한 여러 가지 기상 정보가 담고 있다.


○ 데이터 전처리

- 2014-2020 train 데이터 중 ‘존재하는 시간대에서 기상 관측치가 없는 경우’와 ‘아예 시간대 자체가 없는 경우’ 두 가지에 대해 둘 다 선형보간 방식으로 결측치 처리 : 모델 실행 시 결측치로 인한 에러 방지를 위함
- 호우주의보 피쳐 추가
- elev_lag_168h 변수 추가 : 7일(168h)전 지하수 수위 lag 반영
- 시계열 정상성 검정(ACF/ADF) : 정상성에 가깝지만, 급격한 변동이 존재.


Ⅲ. 모델 선정 과정

본 연구에서 지하수위 예측을 위해 다양한 모델을 검토한 결과, TFT(Temporal Fusion Transformer) 모델을 최종적으로 선정하였다. 모델 유형을 정하기 위해 시계열 데이터 정상성 검정을 진행했다. 검정은 데이터 PLOT, 자기상관함수(AutoCorrelation Function, ACF), ADF(Augmented Dicky-Fuller)의 3가지 방법을 사용했고 결과는 다음과 같다.


원시 지하수 수위



[그림 1] 데이터 plot



[그림 2] 자기상관함수 시각화



[그림 3] ADF 결과

앞서 진행한 시계열 데이터 정상성 검정에서 자기상관함수 결과에선 비정상적으로, ADF 결과에선 정상적임을 확인했다. 이 두 가지 결과는 ADF는 계절성 주기를 반영하지 못한다는 점을 미루어 보아 비정상성으로 판정할 여지가 존재한다. 그러나 데이터 PLOT에서 데이터가 끊임없이 변동하는 경향을 보이지만, 그 크기가 유의미하게 크지 않고 매년 변동이 반복되며 일정 수준을 유지하기 때문에 안정적인 정상성 시계열 데이터처럼 보였다. 결론적으로 우리는 데이터 plot의 결과 해석에 중점을 뒀 정상성을 가진 시계열 데이터지만 비정상적인 급변 구간이 존재한다고 판단했다.

이에 따라 본 연구는 이러한 지하수위의 비정상적 급변 반응을 예측하는 것을 모델 사용의 목적으로 하며, 복잡한 시계열의 비선형 관계와 다변량 변수 간의 상호작용을 학습할 수 있는 **딥러닝 모델**을 사용하기로 했다. 우선 딥러닝에 사용할 입력 변수를 정의하기 위해 랜덤 포레스트(Random Forest)를 실시했다. 랜덤 포레스트는 변수 간 상호작용을 효율적으로 탐지하고 변수 중요도를 산출해 낼 수 있는 모델이다. 본 연구에서는 랜덤 포레스트를 통해 지하수위 변동에 기여하는 변수의 중요도를 도출하는 데에 사용했으며, 그 결과 전 기전도도, 수온, 현지 기압, 기온 순이다.

이후 예측 초기 모델로 LSTM을 선택했다. LSTM은 시계열 데이터의 장기 의존성과 기상 요인의 누적 영향을 학습하기에 효과적인 모델이며, 구현이 쉽다는 점에서 예측 초기 모델로 선택했다. 모델 실행 결과 LSTM은 12개 관측 지점을 통합적으로 학습하지 못한다는 한계가 있었고, 무엇보다 급변 반응에 민감하게 반응하지 못한다는 치명적인 단점이 존재했다.

따라서 본 연구에서는 이러한 한계를 보완하기 위해 시계열 데이터의 장기 의존성을 효과적으로 학습할 수 있고, 다변량 입력과 다지점 데이터를 동시에 처리할 수 있으며 본 연구에서 모델 사용의 목적인 지하수위의 비정상적 급변 반응을 효과적으로 예측할 수 있는 **TFT 모델**을 최종 예측 모델로 선정하였다.

IV. 함양특성 분석

○ ACF와 FFT

ACF(Autocorrelation Function)와 FFT(Fast Fourier Transform)는 시계열 내 반복 패턴을 탐색하기 위한 대표적인 통계·신호분석 기법으로 본 연구에서는 12개 지하수 관측정의 수위를 대상으로 ACF와 FFT를 적용하여 지하수위 변동의 주기성을 분석하였다.

대부분의 지점에서 ACF 및 FFT 분석 결과 약 1년(≈ 365 일)의 주기가 뚜렷하게 나타나 지하수위가 계절적 강수 패턴에 따라 반복적으로 상승·하강하는 전형적인 연주기성을 보였다. 특히, 6.7.9.10번 지점에서는 약 180~210일 수준의 반년주기가 검출되었다. 이는 여름철 장마(6~7월)와 가을철 태풍(9~10월)에 따른 두 번의 주요 강수 피크가 지하수위 변동에 반영된 결과로 해석된다.

Site	ACF주기 (일)	FFT주기 (일)
1	295	365.3
2	294	365.3
3	286	365.3
4	286	365.3
5	294	365.3
6	303	182.6
7	306	182.6
8	293	365.3
9	294	182.6
10	294	213.1
11	286	365.3
12	295	365.3

[표1]지점별 ACF 및 FFT 주기

○ CCF

강수와 지하수위 간의 상호상관(Cross-Correlation Function, CCF) 분석을 통해 강수가 지하수위 변화에 미치는 시간적 지연(lag)을 정량화하였다.

- 강우는 간헐적으로 발생하지만 지하수위의 경우는 연속적으로 측정되며, 발생한 강우가 지하수까지 도달하는데 시간차(Time lag)가 발생하기 때문에 지하수위와 강수량의 직접적인 상관관계는 낮음 (김인철 외, 2021)
- 강수량과 지하수위 간 직접적인 상관관계 분석은 강수가 발생한 시간과 강수가 지하수위 변동에 영향을 주는 시간의 차이인 지연시간을 통해 분석할 수 있음 (허준용 외, 2021)

CCF를 통해 두 series가 선후관계에 있는지 유사도를 측정 가능하다.

Site	최대상관lag (시간)	Corr
1	34	0.12
2	17	0.17
3	49	0.12
4	20	0.15
5	9	0.14
6	7	0.14
7	120	0.12
8	25	0.15
9	32	0.17
10	6	0.08
11	10	0.17
12	15	0.15

[표2] 지점별 lag 시간

강수 - 지하수 상호상관(CCF) 분석 결과, 대부분 지점에서 강수 발생 후 10~36시간 이내에 지하수위가 상승하는 것으로 나타났다. 상관계수는 0.12~0.17 수준으로, 강수 변화가 지하수위 변동의 약 10~20%정도를 설명하였다. 이는 대체로 강수 직후 빠르게 반응하는 표층 함양형 지역의 특성을 의미한다. 반면, 3번(49시간)과 7번(120시간) 지점이 상대적으로 긴 lag를 보였으며, 이는 저투수층 또는 심부 대수층을 통한 느린 함양 과정을 반영하는 것으로 해석된다. 7번 지점이 약 5일의 지연이 나타나 강수의 직접적 영향보다는 다른 요인이 지배적인 것으로 판단된다.

○ 지점별 함양특성 분석

Site	River	수리전도도	표고	평균 전기전도도	평균 지하수위(m)
1	영섬권역	0.0132	108.29	721.94	105.518
2	낙동강권역	0.01879	204.58	229.51	201.978
3	한강권역	0.1507	59.17	514.88	54.407
4	영섬권역	0.0008457	82.07	211.17	77.510
5	영섬권역	0.004522	84.72	394.61	80.853
6	금강권역	0.000794	144.22	423.07	140.612
7	낙동강권역	0.0001332	128.91	260.82	125.133
8	영섬권역	0.00159	226.849	191.16	224.217
9	낙동강권역	0.000171	218.862	195.12	214.230
10	영섬권역	0.000382	30.203	369.67	27.586
11	영섬권역	0.0003328	8.38	368.80	2.933
12	영섬권역	0.0003048	116.75	407.71	113.381

[표3] 지점별 관측정보

- 지점 1: 중간 표고 및 투수성, 빠른 반응, 구릉성 충적층. 강수 직후 수위 상승, 즉시형 반응.
- 지점 2: 고표고, 중투수, 고지대임에도 비교적 반응 빠름. 중간 완충형.
- 지점 3: 저표고, 고투수, 투수성 높고 lag 길어 재충전 루트가 길거나 완충성 큼.
- 지점 4: 저투수 기반암층, 반응은 중간이나 corr 낮음 → 점토질 기반 저장형.
- 지점 5: 저표고, 보통 투수성, 평야형 빠른 반응 지역, 빠른 재충전형
- 지점 6: 중표고, 저투수, 함양 빠르고 상관 뚜렷. 얇은 지하수면 구조.
- 지점 7: 저투수 기반암층, → 완충형 or 불투수층 반응.
- 지점 8: 고표고, 중투수, 지형적 함양 지연, 느린 반응
- 지점 9: 고표고, 저투수, 산지형 기반암 지역, 강수 영향 늦게 반영.
- 지점 10: 저표고, 저투수, 저지대 완충형, 재충전 느림.
- 지점 11: 매우 낮은 표고, 저투수, 평야형이나 불투수층 영향으로 약한 반응.
- 지점 12: 중표고, 저투수, - 느린 반응형, 산지 재충전 지연형

V. 실험 및 평가

○ 데이터 전처리

함양 특성 분석의 결과를 바탕으로 본격적으로 TFT 모델 실험에 나섰다. 다만 이 과정에서 기존에 했던 데이터 전처리에서 약간의 차이점이 생겼다. 그것은 바로 TFT 모델에 맞춰서 모델 학습 성능 향상을 위한 세부적인 추가 가공 과정을 수행했다는 것이다. 우선, 결측치 처리는 모든 지점별 시계열의 시간 연속성을 보장하기 위해 선형보간을 적용하였다. 또한 보간에 의해서 결측이 채워진 구간은 추후 모델 해석 시 모델이 이를 구분할 수 있도록 'is_precipitation_missing'이라는 피처를 추가했다. 이는 그냥 선형보간을 해도 상관없이 다른 기상 수치와는 별개로 강수량은 보간했을 때의 0의 값이 실제로 강수량이 0인지, 아니면 보간에 의해서 생긴 0인지를 모델이 구분할 수 없기 때문이다. 따라서 보간한 모든 시간대는 해당 피처의 값을 1로 주었고, 아닌 경우는 모두 0으로 처리했다.

다음으로 지하수 수위의 경우 7일(168h) 래그 외에 14일(336h), 21일(504h) 래그를 추가하여 장기 추세를 함께 반영하였다. 다만 이 역시도 지점 별로 2014-01-01부터 2013년의 데이터가 없기 때문에 첫 n일은 래그를 채울 수 없는 상태였다. 따라서 임의로 2014-01-01 00시의 지하수 수위로 모두 대체 해버리고, 이 역시도 모델에게 우리가 임의로 대체한 값을 알려주는 'is_prefill_168h, is_prefill_336h, is_prefill_504h'의 플래그 컬럼을 추가하였다. 이 또한 임의로 채운 시간대면 해당 피처의 값은 1, 아니면 0으로 처리했다.

마지막으로, 강수 관련 피처를 조정하였다. 기존의 호우주의보 피처는 제외하였으며, 대신 하루 동안의 누적 강수량(sum_of_rain_24h)을 추가하였다. 이는 CCF 분석 결과를 반영한 것으로, 결과를 해석해보면 지점 대부분에서 강수 발생 후 10~36시간 이내에 지하수위가 반응하게 된다. 따라서 단발성 강수량보다 최근 24시간 동안 비가 얼마나 집중적으로 내렸는지가 지하수위의 급변을 유발하는 것을 알 수 있다. 따라서 해당 피처를 넣었고, 이 역시도 지하수 수위 래그값과 마찬가지로 첫 24시간은 임의로 지정할 수 밖에 없었으므로, filled 플래그(is_filled_sum_24h) 추가해주었고, 같은 방식으로 임의의 시간대면 1, 아니면 0으로 처리했다.

이외에도 지하수 수위 래그의 다양화, 누적 강수량의 다양화, 이동 평균 피처, 주기성 피처 등 다양한 피처들을 추가로 삽입하자는 의견이 있었다. 다만, 파일의 크기가 커지면 커질수록 당연히 모델이 학습하는 시간이 오래 걸려 현실적인 이유로 해당 피처들만 가지고 실험을 진행했다.

○ 모델 구조 및 학습 설정

모델의 주요 설정은 다음과 같다.

- 학습률(learning rate) : 0.0026
- 은닉층 크기(hidden_size) : 48
- 연속형 변수 은닉 크기(hidden_continuous_size) : 24
- 어텐션 헤드(attention_head_size) : 2
- 드롭아웃(dropout) : 0.25
- 출력 크기(output_size) : 7
- 손실 함수(loss) : Quantile Loss ($\tau = [0.1, 0.5, 0.9]$)
- 최적화 기법(optimizer) : Adam
- 에폭 수(max_epochs) : 3
- 배치 크기(batch_size) : 256
- 병렬 처리(worker 수) : 4

모델 학습은 2014-2018년 데이터를 학습(train) 구간으로, 2019-2020년 데이터를 검증(validation) 구간으로 사용하였다. 모든 시계열은 series_id(지점 단위)로 구분되어 모델이 지점별 특성과 패턴을 동시에 학습할 수 있도록 구성하였다. 입력 구간은 과거 168시간(7일)의 정보를 인코더로 입력하고, 이후의 예측 구간을 24시간 단위로 출력하도록 설정하였다.

다음으로 학습 과정은 PyTorch Lightning의 Trainer 모듈을 활용하여 자동화하였다. 참고로 모델의 주요 설정은 Python 기반의 하이퍼파라미터 최적화 프레임워크인 'Optuna'를 사용해 위와 같이 정했다.

우선 훈련 시에는 GPU 가속 환경에서 bf16-mixed 정밀도(precision = 'bf16-mixed') 설정을 적용하여 연산 효율을 높였으며, 기울기 폭주를 방지하기 위해 gradient clipping 값 0.1을 지정하였다.

검증 데이터 존재 여부에 따라 다른 콜백 구조를 적용하였다. 검증 세트가 있는 경우에는 EarlyStopping(monitor='val_loss', patience=5)과 ModelCheckpoint(save_top_k=1, mode='min')을 사용하여 최적 모델만 저장하였고, 검증 세트가 없는 경우에는 EarlyStopping을 생략하고 마지막 학습 상태(save_last=True)만 기록했다.

학습은 Trainer.fit() 함수로 수행되었으며, 모든 학습이 완료된 후 검증 데이터가 존재하는 경우에는 best_model_path, 그렇지 않은 경우에는 last_model_path를 최종 모델로 사용하였다.

이와 같은 설정을 통해 모델은 안정적인 학습 수렴에 달성할 것으로 예상되었으나, 제일 핵심이 되는 예폭 수를 10 이상으로 늘리지 못한 것이 성능 저하의 핵심 원인이 되었다. 이 역시도 학습 시간과 관련된 이슈로, 과적합 여부도 제대로 확인해보지 못하고 최적의 하이퍼파라미터만 찾다가 실험 기간을 낭비해버린 것이 아쉬움으로 남는다.

◦ 성능 평가 지표

해당 프로젝트에서는 모델의 예측 성능을 정량적으로 평가하기 위해 Nash-Sutcliffe Efficiency (NSE) 와 Kling-Gupta Efficiency (KGE) 두 가지 지표를 사용하였다. 두 지표 모두 수문학 분야에서 시계열 모형의 정확도 평가에 널리 활용되는 대표적인 성능 척도이다.

1) NSE (Nash-Sutcliffe Efficiency)

$$NSE = 1 - \frac{\sum_{t=1}^T (y_t - \hat{y}_t)^2}{\sum_{t=1}^T (y_t - \bar{y})^2}$$

[그림 4] NSE 계산 수식

여기서 y_t 는 실제 지하수위, $\hat{y}_t$ 는 예측 지하수위, $\bar{y}$ 는 실제값의 평균이다. NSE 값은 1에 가까울수록 예측 성능이 우수함을 의미하며, 0은 단순히 평균값으로 예측했을 때와 동일한 수준, 음수는 평균보다도 낮은 예측 성능을 나타낸다.

2) KGE (Kling-Gupta Efficiency)

$$KGE = 1 - \sqrt{(r - 1)^2 + (\alpha - 1)^2 + (\beta - 1)^2}$$

$$r = \text{corr}(y, \hat{y}), \quad \alpha = \frac{\sigma_{\hat{y}}}{\sigma_y}, \quad \beta = \frac{\mu_{\hat{y}}}{\mu_y}$$

[그림 5] KGE 계산 수식

KGE는 단순 상관계수로는 설명할 수 없는 분산비(α)와 평균비(β)까지 함께 고려하여, 모형의 형태 적합도(상관성), 변동성 재현력, 평균 바이어스를 종합적으로 평가한다. 값이 1에 가까울수록 모형의 전반적인 재현력이 우수함을 의미한다.

이에 더해 해당 프로젝트에서 NSE와 KGE를 사용한 원인에 대해 알아보려고

한다. 두 지표 간의 대표적인 차이점이라면, KGE 값에 비해 NSE 값이 오차에 좀 더 민감하게 반응한다는 것이다. 즉, KGE는 지하수 수위 예측에 대한 전반적인 재현력에 초점을 뒀다면, NSE는 지하수 수위가 급변하는 것을 얼마나 잘 포착했는지를 계산하는 척도라고 해석할 수 있게 되는 것이다.

◦ 결과 분석 및 시각화

(본격적인 결과 분석에 앞서 해당 결과는 최종 학습 및 테스트 단계의 결과가 아닌, 모델 구조와 전처리 설정 검증을 위한 중간 실험 결과임을 밝힙니다.)

	NSE	KGE
site		
1	0.631843	0.832715
10	-4.129678	0.338565
11	0.524575	0.810174
12	0.783724	0.829845
2	0.690092	0.861751
3	0.621801	0.855486
4	0.753119	0.845572
5	0.768431	0.851585
6	0.909593	0.955529
7	0.294205	0.800269
8	0.688340	0.840394
9	0.706008	0.856579

전체 평균 성능 지표:

NSE0.270171

KGE0.806539


dtype: float64

[그림 6] 검증 데이터의 전체 평균 성능 지표


[그림 7] 지점별 NSE, KGE 값

[그림 6]은 전체 지점의 예측 성능을 요약한 그래프로, 평균 NSE는 0.27, 평균 KGE는 0.81로 나타났다. 즉, 모델이 전반적인 시계열 형태를 비교적 안정적으로 재현하고 있으나, 일부 지점에서는 여전히 변동 구간의 반응이 다소 부정확함을 확인할 수 있다.

[그림 7]는 지점별 NSE 및 KGE 지표를 비교한 결과로, 대부분의 지점이 KGE 기준으로 0.8 이상을 기록하며 일정 수준의 형태 재현성을 그려낸 반면, NSE의 경우 지점 간 편차가 크게 나타났다. 특히 6번 지점이 가장 높은 성능($NSE \approx 0.91$, $KGE \approx 0.96$)을 보였고, 10번 지점은 음수의 NSE(-4.13)로 가장 낮은 예측력을 보였다. 이러한 지점별 차이는 지질·지형적 특성과 함께, 해당 지역의 강수 패턴 및 기상 데이터 품질에 따라 모델 반응이 달라졌기 때문으로 해석된다.



[그림 8] 가장 높은 성능인 6번 지점의 real vs predict 비교 그래프 (2019-2020)



[그림 9] 가장 낮은 성능인 10번 지점의 real vs predict 비교 그래프 (2019-2020)

[그림 8]과 [그림 9]는 각각 성능이 가장 우수했던 6번 지점과 가장 낮았던 10번 지점의 실제 수위와 예측 수위를 비교한 그래프이다. 6번 지점에서는 전체 추세와 강수 반응 구간 모두에서 실제값과 예측값이 잘 일치하는 반면, 10번 지점은 수위가 낮은 구간에서 예측이 불안정하게 진동하며 실제값을 따라가지 못하는 모습을 보였다. 종합적으로, TFT 모델은 다변량 입력과 시간적 의존성을 동시에 반영함으로써 대부분의 지점에서 지하수위 변동 경향을 합리적으로 재현하였으나, 일부 지점(특히 저표고·저투수 지역)에 대해서는 추가적인 변수 확장과 보정이 필요함을 확인하였다.

○ 종합 논의 및 한계

해당 프로젝트는 기상 및 지하수 데이터를 활용하여 TFT 모델 기반의 지하수위 예측을 시도하는 것이었다. 2019-2020년 구간 검증에서는 일부 지점에서 양호한 재현력을 보였으나, 2021-2023년 예측 구간에서는 전반적으로 성능이 저하되는 결과를 확인하였다. 이는 모델 구조 자체의 문제라기보다, 다음과 같은 복합적인 요인에서 비롯된 것으로 분석된다.

첫째, 데이터 분포의 변화(Data Drift) 문제이다. 2021년 이후에는 강수 패턴과 기온의 계절적 진폭이 이전 학습 구간(2014-2020)에 비해 달라졌으며, 특히 특정 해(2022년)의 장마 집중도 및 강우 지속시간이 비정상적으로 높았다. TFT 모델은 과거의 패턴을 중심으로 학습되었기 때문에, 이와 같은 새로운 이상 기상 조건에 충분히 적응하지 못했다.

둘째, 관측 환경의 불균형이다. 12개 지점 중 일부는 결측치나 관측 불연속 구간이 상대적으로 많았으며, 이로 인해 전처리 과정에서의 보간 구간이 과도하게 늘어났다. 특히 강수량과 전기전도도처럼 지하수 반응에 직접 영향을 주는 주요 변수에서 결측 비율이 높은 지점의 경우 예측력이 현저히 낮게 나타났다.

셋째, 모델의 지역 일반화 한계이다. TFT는 다지점 학습을 통해 전역적 패턴을 학습하지만, 개별 지점의 지질 구조나 함양 지연 특성 같은 국지적 요인을 직접 반영하지는 못한다. 이로 인해 반응 속도가 느린 저투수층 지역(예: 10번 지점 등)에서는 강수-지하수 반응 시차를 제대로 학습하지 못하고, 결과적으로 NSE가 음수로 나타나는 등 심한 예측 실패를 보였다.

넷째, 학습 데이터의 시간적 한계도 성능 저하의 한 요인으로 추정된다. 모델은 7년치(2014-2020) 데이터를 기반으로 학습되었지만, 지하수위 변동에는 다년 주기의 기후 주기(ENSO, 장기 강수 편차 등)가 존재한다. 즉, 훈련 데이터만으로는 장기 순환적 요인을 충분히 포착하기 어려웠던 것이다. 결국 본 연구

의 TFT 모델은 단기(검증 구간)에서는 일정 수준의 성능을 보였지만, 장기(예측 구간)로 확장할 때는 시간적 데이터 편향과 지역적 다양성을 충분히 보정하지 못했다. 이는 단순히 모델의 한계가 아니라, 지하수위 예측 문제의 구조적 복잡성을 보여주는 결과이기도 하다.

하지만 무엇보다도 순전히 프로젝트 이해도 부족이 가장 큰 원인이 되었다. TFT 모델을 채택했지만, 초기 파이프라인을 형성하는데 상당한 시간이 걸렸고, 그 이후에도 여러 가지 이유로 인해 모델에게 충분한 학습 시간을 제공해주지 못했다. 최적의 데이터셋과 파라미터를 찾기 위해 시간을 허비하였고, 결과적으로 GPU의 한계로 인해 epoch 수를 10번도 채 넘겨보지 못한 점이 가장 큰 원인이라고 생각한다.

VI. 기대효과

지속 가능한 수자원을 위한 지하수 함양 특성 분석 및 AI 기반 지하수위 변동 예측을 통해 다음과 같은 기대효과를 도출할 수 있다.

① 지속 가능한 수자원 관리 체계 구축

강수 및 기상 요인의 변동성을 반영한 지하수위 예측 결과를 통해 지점별 수자원 관리의 선제적 의사결정이 가능하다. 이를 통해 안정적인 물관리 체계 구축에 기여할 수 있다.

② AI 기반 예측의 활용성

강화시공간적 특성이 다른 여러 지점을 동시분석 가능한 TFT 모델을 적용함으로써 예측 정확도와 효율성이 크게 향상되었다. 이를 통해 실시간 모니터링 및 수위 예측 시스템에 AI 기술을 적용할 수 있는 기반을 마련한다.

③ 과학적 인사이트 제공

강수량, 기온, 전기전도도 등 기상·수문 요소가 지하수위에 미치는 상호작용을 정량적으로 분석하여, 지하수 함양의 주요 결정 요인을 규명할 수 있다. 향후 지하수 함양 정책, 지하수 자원 취약성 평가 등에 활용될 수 있다.

더 나아가 본 연구를 통해 지속 가능한 수자원 확보와 물관리 정책의 데이터 기반 의사결정을 지원할 수 있을 것이다.